실생활 데이터 기반 수학적 모델링 및 한계점 분석

수행평가 2 · 결과 및 계산 근거 (원본 디자인 제출용 문서와 별도)
제출용 DOCX·PDF 에 포함된 주요 수식과 분석을 GitHub 에서도 검토할 수 있도록 정리한 문서이다.

항목

내용

탐구 주제

서울시 공공자전거 대여량의 시간적 주기성과 삼각함수 모델의 예측 정확도 비교

데이터

UCI Machine Learning Repository, *Seoul Bike Sharing Demand* (2020)

출처

https://doi.org/10.24432/C5F62R

표본 수

원본 8,760 개, 미운영 295 개 제외, 분석 8,465 개

평가 방식

같은 날짜가 여러 집합에 포함되지 않도록 날짜 단위 분할

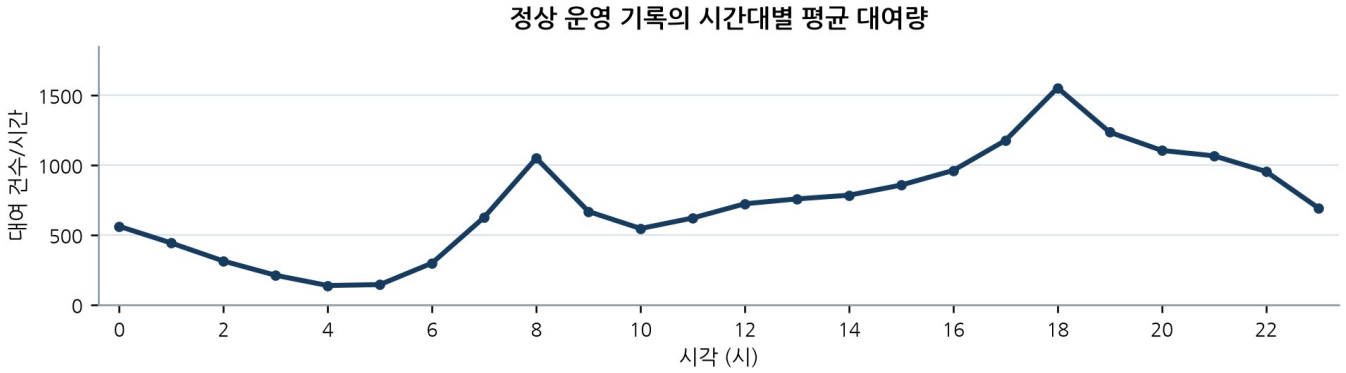
학습 / 검증 / 테스트

5,832 / 1,121 / 1,512 개의 시간별 관측값

1. 수집한 데이터 정리 및 시각화

2017 년 12 월부터 2018 년 11 월까지 365 일 동안 관측한 8,760 개의 시간별 대여 기록을 사용하였다. 14 개 열에는 날짜, 시각, 대여량, 기온, 강수량, 계절, 공휴일, 운영 여부 등이 포함된다. 시간대별 반복 패턴을 함수로 모델링할 수 있고 기상 변수가 포함되어 있어 모형의 한계도 실험할 수 있다고 보았다.

서비스 미운영 시간은 이용자가 자전거를 대여하지 않은 것과 다르므로 분석에서 제외했다. 날짜·시각 중복과 필수 열 결측값을 점검한 뒤 정상 운영 기록 8,465 개의 시간대별 평균을 구했다.



전체 정상 운영 시간의 시각별 평균

시각

정상 운영 시간의 평균 대여량

04 시

약 137.5 건/시간

08 시

약 1,050.2 건/시간

18 시

약 1,554.0 건/시간

오전과 오후에 대여량이 크게 증가하는 구간이 각각 존재한다. 그래서 24 시간 성분 하나만 사용하는 경우보다 **12 시간 성분을 추가**하면 오차가 줄어들 것이라는 가설을 세웠다.

날짜별로 계절과 주말 여부를 구분하고 고정 시드 42 로 학습 243 일, 검증 47 일, 테스트 63 일을 할당했다. 분할된 날짜는 겹치지 않는다. 모델 계수는 학습 데이터에서 추정한다.

2. 수학적 모델링 및 예측값 도출

시각을 $t \in \{0, \ldots, 23\}$, 실제 대여량을 y, 주말이면 1 인 지표를 w로 정의한다.

가. 24 시간 주기: M1

$$\hat{y}_1(t) = a_0 + a_1 \sin(2\pi t/24) + b_1 \cos(2\pi t/24).$$

나. 12 시간 성분 추가: M2

$$\hat{y}_2(t) = a_0 + a_1 \sin(2\pi t/24) + b_1 \cos(2\pi t/24) + a_2 \sin(4\pi t/24) + b_2 \cos(4\pi t/24).$$

학습 데이터만으로 추정한 계수는 다음과 같다.

계수

a_0

a_1

b_1

a_2

b_2

값

722.781

-403.395

-91.721

-183.426

-116.934

두 조화 성분의 진폭은 각각

$$A_{24} = \sqrt{a_1^2 + b_1^2} \approx 413.69,\ A_{12} = \sqrt{a_2^2 + b_2^2} \approx 217.53.$$

진폭비 $A_{12}/A_{24} \approx 0.526$으로, 12 시간 주기 성분을 무시하기 어렵다. 단, 이 비율 자체가 모델의 예측 정확도를 나타내는 것은 아니다.

다. 주중·주말을 구분하는 M3

$$\phi(t) = \begin{bmatrix} 1 & \sin(2\pi t/24) & \cos(2\pi t/24) & \sin(4\pi t/24) & \cos(4\pi t/24) \end{bmatrix}^T.$$

$$\hat{y}_3(t, w) = \phi(t)^T \beta_3 + w\,\phi(t)^T \gamma_3.$$

M3 은 M2 와 같은 주기 기저를 사용하더라도 **10 개 계수를 전부 독립적으로 다시 추정**한다. 실제로 M2 의 상수항은 722.781, M3 의 주중 상수항은 740.295 이므로 두 모델의 계수를 혼동해서는 안 된다.

라. 최소제곱법

각 관측값의 삼각함수 값과 주말 지표를 설계행렬 X의 각 행에 배치한다. 그러면

$$\hat{y} = X\beta,\ \hat{\beta} = \arg\min_{\beta} \| X\beta - y \|_2^2.$$

정규방정식은 $X^T X \beta = X^T y$이다. 실제 계산은 역행렬을 직접 구하지 않고 numpy.linalg.lstsq 로 수행했다. 입력에 삼각함수가 들어 있어도 미지의 계수에 대해서는 선형이다.

마. 한 시각의 실제 예측값

테스트 날짜인 **2017 년 12 월 2 일 08 시**의 관측 대여량은 219 건이었다.

모델

예측량

절대오차

M1

419.291

200.291

M2

636.609

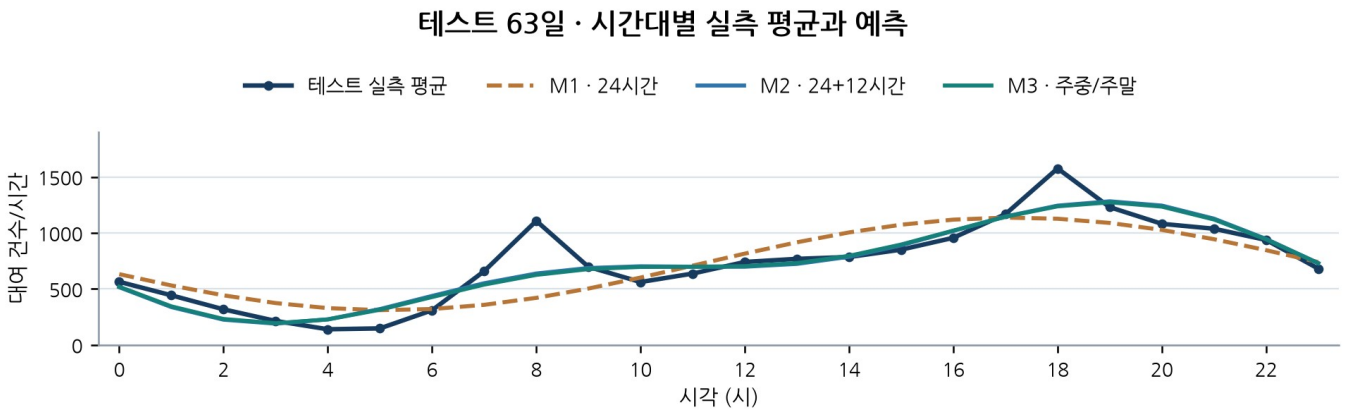
417.609

M3

347.717

128.717

예를 들어 M2 의 오차는 $|219 - 636.609| = 417.609$이다. 이 하루만 보면 M2 가 M1 보다 크게 틀렸다. 모델별 **전체 테스트 오차와 개별 날짜의 오차는 구분**해서 해석해야 한다. 계산에는 반올림 전 계수를 사용했다.



테스트 날짜의 시간대별 평균 비교

3. 오차 분석, 한계점 및 개선 방안

가. 전체 테스트 오차

$$MAE=\frac{1}{n}\sum_{i=1}^{n}\left|y_i-\hat{y}_i\right),RMSE=\sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i-\hat{y}_i\right)^2}.$$

모델

테스트 MAE

테스트 RMSE

R^2

평균만 예측

508.296

633.756

-0.0003

M1: 24 시간

430.716

565.230

0.2044

M2: 24+12 시간

414.978

541.564

0.2696

M3: 주중·주말

405.584

528.761

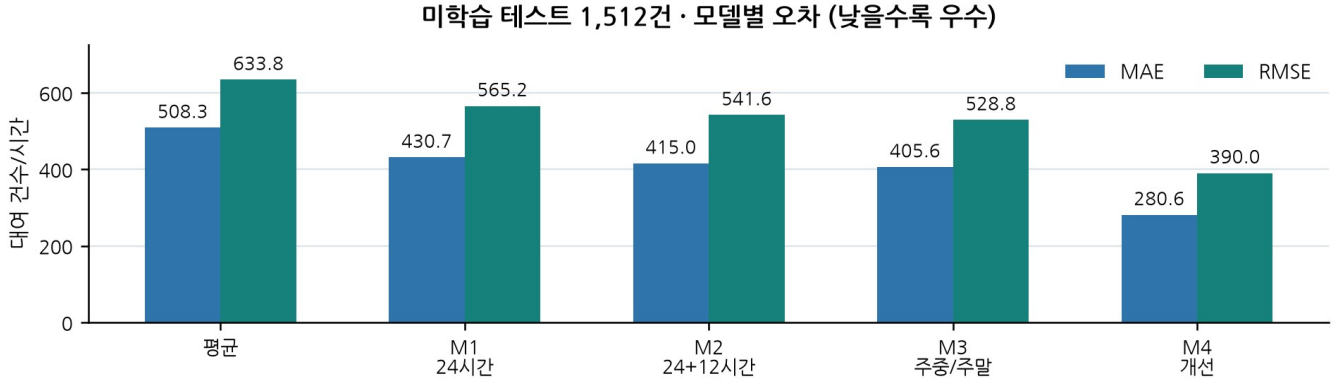
0.3037

M4: 기상·계절 추가

280.575

389.954

0.6213



테스트 오차 비교

M1 에서 M2 로 확장하면 MAE 는 $(430.716 - 414.978)/430.716 \times 100 \approx 3.65\,\%$ 감소한다. 그러나 M3 의 R^2는 0.3037 로 대여량 변동의 상당 부분이 설명되지 않는다.

나. 오차 원인을 잔차로 분석

잔차를 $e_i = y_i - \hat{y}_i$로 정의하면 평균 잔차가 양수일 때는 과소예측, 음수일 때는 과대예측한 것이다.

테스트 집단

M3 평균 잔차(건)

M3 RMSE(건)

겨울 (384 개)

-492.701

575.837

봄 (384 개)

+2.945

458.688

여름 (384 개)

+322.684

605.771

가을 (360 개)

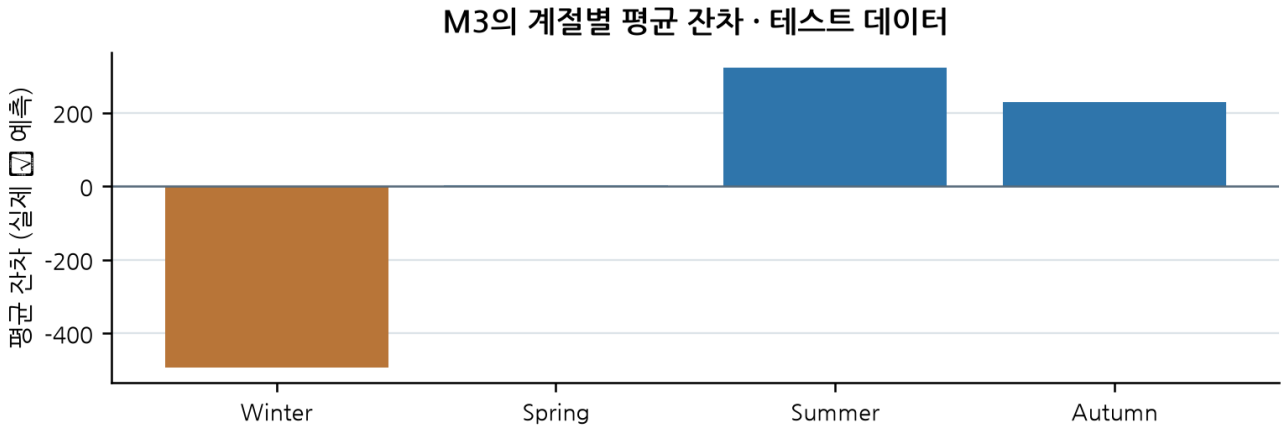
+228.286

452.473

강우 시간 (66 개)

-580.561

747.179



계절별 평균 잔차

겨울에 실제보다 평균 약 493 건을 많이 예측한다. 여름에는 평균 약 323 건을 적게 예측한다. 이는 계절 변수를 생략한 모델의 구조적 한계라는 근거가 된다.

집단 s에서 평균 잔차를 $\acute{e}_s$라 하면 다음 항등식이 성립한다.

$$RMSE_s^2 = Var_s(e) + \bar{e}_s^2.$$

겨울은 $(492.701/575.837)^2 \approx 0.732$이므로, 겨울철 평균제곱오차 중 약 73.2%가 한 방향의 평균 편향 제곱에 해당한다. 현실적인 이유를 추측하는 대신 오차의 구조를 수학적으로 확인한 것이다.

다. 개선 모델 M4 의 수학적 정의

기존 M3 의 계수를 다시 추정하면서 관측 기온 T(℃), 강수량 R(mm), 공휴일 지표 H, 봄·여름·가을 더미변수를 함께 사용하였다.

$$\begin{aligned}\hat{y}_4(t, w, T, R, H, S) = &\phi(t)^T \beta_4 + w\,\phi(t)^T \gamma_4 \\ &+ \theta_T (T/10) + \theta_R (R/10) + \theta_H H \\ &+ \delta_{spr} S_{spr} + \delta_{sum} S_{sum} + \delta_{aut} S_{aut}.\end{aligned}$$

겨울은 계절 더미변수의 기준 집단(모두 0)이다. 이렇게 하면 설계행렬에 10 개의 주기·주말 항과 6 개의 추가 설명변수가 포함되어, **총 16 개 계수**를 한 번에 추정한다.

규제 강도는 검증 집합에서 $\lambda \in \{0, 1, 10, 100, 1000\}$의 RMSE 를 비교했다.

λ	검증 RMSE
0	424.328
1	424.485
10	425.848
100	434.663
1000	461.902

선택된 값은 $\lambda = 0$이다. 따라서 최종 M4 는 패널티가 없는 최소제곱 추정이며, **규제를 사용해서 오차가 줄었다고 말할 수 없다**.

M3 에 비해 M4 의 테스트 MAE 가

$$\frac{405.584 - 280.575}{405.584} \times 100 \approx 30.82\,\%$$

감소했다. M4 의 계절별 평균 잔차는 겨울 약 -11.0 건, 여름 약 +43.4 건으로 줄었다. 그러나 강우 시간의 M4 MAE 는 여전히 약 542.4 건이다.

계수의 실제값(반올림 전)은 improved_coefficients.csv 에 기록했고, improved_model.py 로 다시 계산할 수 있다.

해석 범위: M4 는 해당 시간의 **실제 관측 기온과 강수량이 이미 주어진 경우**의 조건부 수요 예측이다. 미래의 기상 조건까지 맞히는 예측 실험이 아니다. 또 M3 의 테스트 오차를 확인한 뒤 M4 에 사용할 변수를 선택했으므로 M4 의 테스트 성능을 엄밀하게 완전히 독립적인 검증 결과로 볼 수는 없다. 독립된 새 연도 자료에서 추가로 평가해야 한다.

4. 탐구 성찰 (자기 평가)

처음에는 하루에 한 번 반복되는 주기만으로 대여량을 설명할 수 있다고 생각했다. 그러나 실제 그래프에서는 오전 8 시와 오후 6 시 부근에 서로 다른 상승 구간이 나와서 12 시간 주기항을 추가했다. 테스트 MAE 가 낮아진 것은 확인했지만, 3.65% 감소만으로 모델이 충분하다고 볼 수는 없었다.

2017 년 12 월 2 일 오전 8 시에는 M2 가 M1 보다 더 크게 틀렸다. 이를 예외로 넘기는 대신 계절별 잔차를 계산했고, 겨울 -492.7 건과 여름 +322.7 건이라는 편향을 확인했다. 연중 모든 날짜를 시간대별 주기함수 하나로 설명하려는 가정 자체에 한계가 있다고 판단했다.

개선 모델에서는 자료에 있는 기온·강수량·계절 변수를 추가해 같은 날짜 분할로 다시 평가했다. M4 의 오차가 줄었어도 강우 시간대의 오차가 남아 있고, 새 연도나 미래 기상 예측을 검증하지 못했다는 점은 분명한 한계다. 특히 M3 의 테스트 잔차를 모델 변경에 참고했기 때문에 M4 결과는 탐색적 비교로 해석하는 것이 맞다.

자기 점검 항목

이번 탐구에서 확인한 내용

다음에 보완할 부분

가설

24 시간 성분만으로 설명할 수 있는지 조사

12 시간 외 고차 조화항의 실제 효과

계산

각 모델 계수를 독립적으로 최소제곱 추정

다른 기간으로 외삽해 검증

오차

계절별 평균 잔차와 편향·분산 구분

강우·공휴일의 상세 영향

검증

날짜 중복 방지, 검증 집합으로 λ 선택

모델 선택까지 독립된 최종 테스트

적용

기상 조건이 주어진 상황에서 M4 개선

실제 미래 날씨 및 비음수 대여량 처리

재현

```
python -m pip install -r requirements.txt
python -m src.run_analysis
python -m src.improved_model
python -m scripts.plot_report_figures
python -m unittest discover -s tests -v
```

실제 데이터를 확인하고 모델을 재학습하면 그래프와 평가 지표를 다시 만들 수 있다. 단일 연도 내 날짜별 분할이라는 한계는 그대로이며 다음 해 예측으로 해석하지 않는다.

원본 자료의 사용 조건: UCI *Seoul Bike Sharing Demand*, CC BY 4.0.